



Distances et Similarité entre des Textes

Jean Barré

23 septembre 2025

Doctorant École Normale Supérieure - Université PSL - LaTTiCe

Représentation Vectorielle des Textes

- Représentations classiques : sac de mots, TF et TF-IDF.
- Représentations modernes : plongements mots et phrases.
- L'hypothèse distributionnelle : le sens d'un mot (ou texte) est déterminé par son contexte.




Figure 1: Figure 2.1 – Projection de textes dans l'espace

Quelle distance entre deux textes ?

- Pour regrouper des textes qui nous semblent proches, il nous faut d'abord définir ce que nous appelons « proche ».
- Nécessité de définir ce qu'est la **distance** entre deux textes.
- **Idée la plus simple :**
 - On choisit un critère d'intérêt (nombre d'occurrences de mots, de mots-outils, de 3-grammes de POS).
 - On calcule la différence, pour chaque mot/mot-outil etc., entre leurs *proportions* dans A et B : ex. A utilise « de » dans 0,5% des cas, B dans 0,3% $\Rightarrow$ différence de 0,2.
 - On **somme ces différences au carré** (valeurs positives) pour chaque mot. Le résultat est la distance entre les deux textes.

Métriques (1) : distance euclidienne

- Agir de la sorte revient à utiliser la distance la plus courante en maths : la **distance euclidienne**.

$$d_2(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

- Mesure habituelle du monde physique.
- Mais *pourquoi* la distance entre deux *textes* se mesurerait comme celle entre une table et une chaise ?

Distance Euclidienne

- Calculée comme la norme de la différence entre deux vecteurs.
- Formule en 2D :

$$d(\vec{u}, \vec{v}) = \sqrt{(u_1 - v_1)^2 + (u_2 - v_2)^2}$$




FIGURE 2.4 – Illustration de l'utilisation du théorème de Pythagore pour définir la norme d'un vecteur (repère orthogonal)

Métriques : Une grande variété...

Distance/Similarity measure	Formula
Manhattan Distance	$\sum_{i=1}^n x_i - y_i $
Euclidean Distance	$\sqrt{\sum_{i=1}^n (x_i - y_i)^2}$
Canberra Distance	$\sum_{i=1}^n \frac{ x_i - y_i }{ x_i + y_i }$
Cosine Distance	$\frac{\sum_{i=1}^n x_i y_i}{\sqrt{\sum_{i=1}^n x_i^2} \sqrt{\sum_{i=1}^n y_i^2}}$
Burrows' Delta	$\frac{1}{n} \sum_{i=1}^n \left \frac{x_i - \mu_k}{\sigma_k} - \frac{y_i - \mu_k}{\sigma_k} \right $
Argamon's Linear Delta	$\frac{1}{n} \sum_{i=1}^n \sqrt{\left \frac{(x_i - y_i)^2}{\sigma_i^2} \right }$
Eder's Delta	$\frac{1}{n} \sum_{i=1}^n \left(\left \frac{x_i - y_i}{\sigma_i} \right \cdot \frac{n - n_i + 1}{n} \right)$
Eder's Simple Delta [9]	$\sum_{i=1}^n \sqrt{x_i} - \sqrt{y_i} $
Argamon's Quadratic Delta	$\frac{1}{n} \sum_{i=1}^n \frac{1}{\sigma_i^2} (x_i - y_i)^2$
Bray-Curtis Dissimilarity	$\frac{\sum_{i=1}^n x_i - y_i }{\sum_{i=1}^n (x_i + y_i)}$
Kulczynski Distance	$\frac{\sum_{i=1}^n x_i - y_i }{\sum_{i=1}^n \min(x_i, y_i)}$
Jaccard Index	$\frac{2 \sum_{i=1}^n x_i - y_i }{\sum_{i=1}^n (x_i + y_i) + \sum_{i=1}^n x_i - y_i }$
Gower Similarity	$\frac{1}{n} \sum_{i=1}^n \frac{ x_i - y_i }{\max_i - \min_i}$
Alternative Gower Similarity	$\frac{1}{n_0} \cdot \sum_{i=1}^n x_i - y_i $
Horn's modification of Morisita's Overlap Index	$\frac{2 \sum_{i=1}^n x_i y_i}{\left(\frac{\sum_{i=1}^n x_i^2}{(\sum_{i=1}^n x_i)^2} + \frac{\sum_{i=1}^n y_i^2}{(\sum_{i=1}^n y_i)^2} \right) \sum_{i=1}^n x_i \sum_{i=1}^n y_i}$
Moutford Index	$\frac{1}{\alpha}$, where α is the parameter of Fisher's log-series
Binomial Index [5]	$\sum_{i=1}^n \frac{x_i \cdot \ln \frac{x_i}{2n} + y_i \cdot \ln \frac{y_i}{2n} - 2n \cdot \ln \frac{1}{2}}{2n}$

Métriques (2) : distance de Manhattan



Figure 3: Krause (1986), *Taxicab Geometry : An Adventure in Non-Euclidean Geometry*. New York : Dover.

$$d_1(x, y) = \sum_{i=1}^n |x_i - y_i|$$

Métrique (3) : Distance de Canberra

Lance & Williams (1966), *Computer Journal* 9(1) :60–64.

$$D_{\text{Canb}}(x, y) = \sum_{i=1}^n \frac{|x_i - y_i|}{|x_i| + |y_i|}$$

- Distance de Manhattan **pondérée**.
- Atténue l'importance de grandes différences numériques ; s'intéresse davantage à l'existence de différences qu'à leur amplitude brute.

Métrique (4) : Delta de Burrows

Burrows (2002), Hoover (2004).

$$\Delta(A, B) = \frac{1}{n} \sum_{i=1}^n \left| \frac{A_i - B_i}{\sigma_i} \right|$$

- Combine **z-scores** (moyenne $\rightarrow 0$, écart-type $\rightarrow 1$) et **distance de Manhattan**.
- Très utilisé en *stylométrie* (prose et poésie), mais efficacité discutée (p. ex. Jannidis et al., 2015).

Pourquoi cette métrique ?

- Peu d'intuitions fermes sur *pourquoi* une métrique serait supérieure à une autre.
- **Argamon (2008)** : incohérence du Delta (z-scores euclidiens + Manhattan).
- Propose deux alternatives :
 - **Delta linéaire d'Argamon** : distance de Manhattan, normalisation par *médiane* et *dispersion*.
 - **Delta quadratique d'Argamon** : distance euclidienne + z-transformation.

Métrique (5) : Similarité Cosinus

$$\cos(\theta) = \frac{A \cdot B}{\|A\| \|B\|}$$

- Représente chaque texte par un vecteur ; compare l'**angle** entre deux vecteurs.
- En textométrie (comptes positifs), $\cos \in [0, 1]$.
- Insensible à la *longueur* brute si normalisé ; très utilisé en IR/TAL.

Distance Cosinus




FIGURE 2.5 – Cercle trigonométrique (source wikipedia)

MÉTRIQUES : EFFICACITÉ (Evert et al., 2017)

- Analyses comparatives des mesures de distance en attribution d'auteur.
- Résultats variables selon langues, genres, prétraitements et normalisations.




Figure 4: Efficacité des métriques (Evert et al., 2017)

MÉTRIQUES : EFFICACITÉ (Evert et al., 2017)




Figure 5: Efficacité des métriques (Evert et al., 2017)

MÉTRIQUE (6) : MINMAX

Koppel & Winter (2014); Kestemont et al. (2016).

$$\text{minmax}(A, B) = 1 - \frac{\sum_{i=1}^n \min(\text{tf}(A_i), \text{tf}(B_i))}{\sum_{i=1}^n \max(\text{tf}(A_i), \text{tf}(B_i))}$$

- Focalise sur les **recouvrements relatifs** (min) par rapport aux unions (max) de fréquences.

NORMALISATIONS DES FRÉQUENCES

- **Z-scores** (Delta de Burrows) : standardiser variables (moyenne 0, écart-type 1).
- **Normalisation de longueur des vecteurs** :
 - L1 (Manhattan), L2 (Euclidienne, la plus courante).
 - L'efficacité de la cosinus peut être reproduite par normalisation de longueur (Jannidis et al., 2017).

- **Pas de cadre théorique unifié** expliquant la pertinence relative des métriques.
- Nécessité d'**expérimenter** sur des corpus : résultats parfois contradictoires.

Réfs utiles :

- Evert, Proisl, Jannidis, Reger, Pielström, Schöch, Vitt (2017). *DSH* 32-2 (suppl.), https://academic.oup.com/dsh/article/32/suppl_2/ii4/3865676
- Kestemont, Stover, Koppel, Karsdorp, Daelemans (2016), DH 2016.

- Étude empirique des paramètres (métriques, normalisations, sélection de traits) en stylométrie.




Figure 6: Jannidis Benchmark

COMMENT DÉCOUPER ?

- Une fois la notion de distance éclaircie, il faut **regrouper** de manière pertinente.
- **Clustering** (partitionnement) : très nombreux algorithmes (*hierarchiques* vs *plats*).
- Les méthodes varient par la définition de l'*homogénéité* et les objectifs de regroupement.

- Les distances entre textes, basées sur des représentations vectorielles, offrent une approche quantitative de la comparaison littéraire.
- Choix de la mesure (euclidienne, cosinus, Jaccard) dépend du type de représentation et de l'application.
- Ces outils facilitent l'analyse des similarités, des influences et des évolutions dans les corpus littéraires.