



Traitement de texte de base

Jean Barre

23 septembre 2025

Doctorant Ecole Normale Supérieure - Université PSL - LaTtice

Expressions Regulieres

Pourquoi les Expressions Regulieres ?

- Utilisees dans presque toutes les taches de traitement du texte.
- Outil puissant pour la recherche et la transformation de texte.
- Indispensables en pretraitement des donnees textuelles.
- Utilisees dans l'analyse des donnees textuelles.
- Employees dans les pipelines de NLP et d'intelligence artificielle.

Principaux Elements de Syntaxe

- . : Correspond a n'importe quel caractere.
- * : Repete zero ou plusieurs fois.
- + : Repete une ou plusieurs fois.
- ? : Rendu optionnel (zero ou une occurrence).
- – : Alternance entre deux motifs.

Classes Utiles

- `\d` : Un chiffre (0-9).
- `\w` : Un caractere alphanumerique.
- `\s` : Un espace.
- `^` : Debut de ligne.
- `$` : Fin de ligne.

Cas d'Usage

- Extraction des dates : `\d{2}/\d{2}/\d{4}`
- Filtrage des adresses email : `\w+@\w+\w+`
- Suppression de la ponctuation : `[\w\s]`

Deux Types d'Erreurs Courantes

- **Faux Negatifs** : Absence de detection de motifs valides.
 - Exemple : Recherche du mot "le" ne capturant pas "Le".
- **Faux Positifs** : Correspondances incorrectes.
 - Exemple : Detection de "le" dans "atelier" ou "baleine".

rappel

- `re.search()`
- `re.match()`
- `re.sub()`
- `re.findall()`
- `re.split()`

Normalisation du Texte

Exemples

- Ne pas retirer la ponctuation a l'aveugle : *Ph.D., AT&T*
- Gestion des prix : *45.55€*
- Dates : *01/02/06*
- URLs : *https://psl.eu/*
- Hashtags : *#tall*
- Emails : *someone@ens.psl.eu*
- Clitiques : *je t'aime, l'honneur*
- Expressions multi-mots : *New York, rock 'n' roll*

Tokenisation

```
>>> text = 'That U.S.A. poster-print costs $12.40...'
>>> pattern = r'''(?x)      # set flag to allow verbose regexps
...      ([A-Z]\.)+        # abbreviations, e.g. U.S.A.
...      | \w+(-\w+)*      # words with optional internal hyphens
...      | \$?\d+(\.\d+)?%? # currency and percentages, e.g. $12.40, 82%
...      | \.\.\.          # ellipsis
...      | [][.,;"'()?:-_'] # these are separate tokens; includes ], [
...      '''
>>> nltk.regex_tokenize(text, pattern)
['That', 'U.S.A.', 'poster-print', 'costs', '$12.40', '...']
```

Figure 1 – Tokenisation par NLTK en 2006

Pourquoi la Tokenisation en Sous-Mots ?

- Les modeles de langue modernes ne traitent pas les mots comme des unites fixes.
- La segmentation en sous-mots permet de mieux gerer :
 - Les mots rares et inconnus.
 - La morphologie des langues agglutinantes.
 - La compression de vocabulaire pour ameliorer l'efficacite du modele.

Principe du BPE

- Algorithme itératif qui fusionne les paires de caractères les plus fréquentes.
- Réduit la fragmentation excessive du texte tout en conservant une granularité fine.
- Utilisé dans de nombreux modèles de NLP, tels que GPT, BERT et T5.

Exemple de Byte Pair Encoding (BPE) sur "programmation"

- **Initialisation :** p r o g r a m m a t i o n
- **Fusion 1 :** m m $\rightarrow$ mm $\rightarrow$ p r o g r a m m a t i o n
- **Fusion 2 :** a mm $\rightarrow$ amm $\rightarrow$ p r o g r a m m a t i o n
- **Fusion 3 :** r amm $\rightarrow$ ramm $\rightarrow$ p r o g r a m m a t i o n
- **Fusion finale :** a t i o n $\rightarrow$ ation $\rightarrow$ programm ation

Resultat : Segmentation en programm + ation

Lemmatisation

Représenter tous les mots sous leur lemme

- Transformation en forme canonique = entree de dictionnaire.
- Exemples :
 - **mange, mangeons, mange → manger**
 - **cheval, chevaux → cheval**
 - **je suis, tu es, il est → etre**
 - **courais, couru, courra → courir**
 - **nouveau, nouvelle, nouveaux → nouveau**

Pourquoi la Lemmatisation ?

Applications

- Analyse sémantique et stylométrique.
- Recherche et indexation dans les corpus.
- Études lexicographiques et lexicologiques.

Variabilité Graphique

- 36 graphies différentes pour "cheval".
- Influence des substitutions phonétiques et orthographiques.
- Exemples : cheval, cheual, chevaux, chival.

forme	occrr.	forme	occrr.
cheval	785	ceux	10
cheual	375	cevaux	10
chevaus	248	ceuaus	9
ceval	98	chiuau	9
chevax	92	cheuaux	8
chevals	84	kevaus	6
ceual	66	chevau	5
cheuaus	65	cevaux	3
chival	34	chivals	3
chevaux	30	cheuas	2
chivaus	27	keval	2
cheuax	23	chaval	1
chiual	23	chavaux	1
cevaus	19	cheua	1
chevas	19	cheualx	1
cheuals	14	cheuau	1
cevals	12	chevalx	1

Apprentissage Profond

- Utilisation des *word embeddings*.
- Reseaux neuronaux convolutifs et recurrents (CNN et RNN).
- Approches adaptees aux langues non standard.

Types et Tokens

Definition

- **Token** : Occurrence d'un mot dans un texte.
- **Type** : Une forme unique de mot.
- Le ratio Types/Tokens donne une estimation de la variété linguistique d'un texte.