

BookNLP-fr

Chaîne de traitement computationnel d'oeuvres littéraires françaises

30 décembre 2025

Antoine Bourgois & Jean Barré

LATTICE - Langues, Textes, Traitements informatiques et Cognition
CNRS & ENS-PSL & Université Sorbonne nouvelle

Introduction au projet BookNLP

Oeuvre(s)
Littéraires

Entrée = texte brut

Chaîne de traitement
BookNLP

- Transformations
- Extraction d'informations
- Annotation automatique

Sorties

Études littéraires

Études culturelles

Études diachroniques

...

Origine du projet BookNLP

Corpus romans
langue anglaise
(15 000)

entrée

Chaîne de traitement
BookNLP

Exemples de Sorties:

- Parties du discours
- Dépendances syntaxiques
- Reconnaissances d'entités nommées
- Groupement des mentions de personnages
- Coréférence pronominale
- Détection du discours direct + locuteur

Étude des archétypes de
personnages dans les
oeuvres de fiction

A Bayesian Mixed Effects Model of Literary Character

David Bamman

School of Computer Science
Carnegie Mellon University
Pittsburgh, PA 15213, USA
dbamman@cs.cmu.edu

Ted Underwood

Department of English
University of Illinois
Urbana, IL 61801, USA
tunder@illinois.edu

Noah A. Smith

School of Computer Science
Carnegie Mellon University
Pittsburgh, PA 15213, USA
nasmith@cs.cmu.edu

Abstract

We consider the problem of automatically inferring latent character types in a collection of 15,099 English novels published

learning: entity types learned in this way will be increasingly similar the more similar the domain, author, and other extra-linguistic effects are between them.¹ While in many cases the topically similar types learned under this assumption

Java BookNLP, ACL 2014

Développement BookNLP-fr

Oeuvres Littéraires
langue française

Chaîne de traitement
BookNLP-fr



Lancement en Juillet 2021

BookNLP-fr, the French Versant of BookNLP A Tailored Pipeline for 19th and 20th Century French Literature

Frédérique Mélanie-Becquet¹ 

Jean Barré¹ 

Olga Seminck¹ 

Clément Plancq² 

Marco Naguib³ 

Martial Pastor⁴ 


Thierry Poibeau¹ 

1. Lattice UMR 8094, École Normale Supérieure - PSL - CNRS - Université Sorbonne Nouvelle , Montrouge, France.
2. MSH Val de Loire UAR 3501, CNRS - Université de Tours - Université d'Orléans , Tours, France.
3. LISN, Université Paris-Saclay and CNRS , Orsay, France.
4. Centre for Language Studies, Radboud University , Nijmegen, The Netherlands.

Abstract. This paper presents BookNLP-fr: the adaptation to French of BookNLP,

BookNLP-fr, Journal of Computational Literary Studies, Novembre 2024


BookNLP-fr : fonctions principales



Fonctions Principales

1. Détection d'entités
2. Résolution de la coréférence
3. Extraction des attributs des personnages

BookNLP-fr : Détections d'entités





Module de Détection d'entités




- **Personnages** (m. Delmare, la reine, lui, elle)
- **Entités temporelles** (date, événements historiques)
- **Infrastructures humaines** (maison, usine, routes)
- **Entités géographiques** (le sud, la mer, Mars)
- **Entités géopolitiques** (la France, la ville, le hameau)
- **Véhicules** (voiture, bicyclette, leur calèche)

Module de Détection d'entités




Réseau de neurones

Modèles préentraînés de reconnaissance d'entités nommées



Modèle de reconnaissance d'entités nommées

Modèles préentraînés de reconnaissance d'entités nommées



Modèles préentraînés de reconnaissance d'entités nommées




Text

- Non, mon amie, non, reprit Ralph, je ne veux point d'un tel sacrifice, je ne l'accepterai jamais. En quoi mon existence est-elle donc plus précieuse que la vôtre ? pourquoi faut-il que vous vous imposiez un avenir odieux pour m'en donner un agréable ? Pensez-vous qu'il me fût possible d'en jouir en sentant que votre cœur ne le partage point ? Non, je ne suis point égoïste jusque-là.

Entités
nommées


Extrait de George Sand. *Indiana*. 1832.



Modèle de reconnaissance d'entités nommées

Modèles préentraînés de reconnaissance d'entités nommées

- Non, mon amie, non, reprit Ralph, je ne veux point d'un tel sacrifice, je ne l'accepterai jamais. En quoi mon existence est-elle donc plus précieuse que la vôtre ? pourquoi faut-il que vous vous imposiez un avenir odieux pour m'en donner un agréable ? Pensez-vous qu'il me fût possible d'en jouir en sentant que votre cœur ne le partage point ? Non, je ne suis point égoïste jusque-là.



- Non, mon amie, non, reprit **Ralph** **PER**, je ne veux point d'un tel sacrifice, je ne l'accepterai jamais. En quoi mon existence est-elle donc plus précieuse que la vôtre ? pourquoi faut-il que vous vous imposiez un avenir odieux pour m'en donner un agréable ? Pensez-vous qu'il me fût possible d'en jouir en sentant que votre cœur ne le partage point ? Non, je ne suis point égoïste jusque-là.

Limites des modèles préentraînés

- Non, mon amie, non, reprit Ralph, je
l'accepterai jamais. En quoi mon existence e
pourquoi faut-il que vous vous imposiez
agréable ? Pensez-vous qu'il me fût possib
le partage point ? Non, je ne suis point égoïs

ce, je ne
la vôtre ?
donner u
e cœur n

tag	meaning
PER	person name
LOC	location name
ORG	organization name
MISC	other name

!=

- **Personnages** (m. Delmare, la reine, lui, elle)
- **Entités temporelles** (date, événements historiques)
- **Infrastructures humaines** (maison, usine, routes)
- **Entités géographiques** (le sud, la mer, Mars)
- **Entités géopolitiques** (la France, la ville, le hameau)
- **Véhicules** (voiture, bicyclette, leur calèche)


Limites des modèles préentraînés

- Non, mon amie, non, reprit Ralph, je ne l'accepterai jamais. En quoi mon existence est-elle plus précieuse que la vôtre ? Pourquoi faut-il que vous vous imposiez un avenir odieux pour m'en donner un agréable ? Pensez-vous qu'il me fût possible d'en jouir en sentant que votre cœur ne le partage point ? Non, je ne suis point égoïste jusque-là.

tag	meaning
PER	person name
LOC	location name
ORG	organization name
MISC	other name


!=

- **Personnages** (m. Delmare, la reine, lui, elle)
- **Entités temporelles** (date, événements historiques)
- **Infrastructures humaines** (maison, usine, routes)
- **Entités géographiques** (le sud, la mer, Mars)
- **Entités géopolitiques** (la France, la ville, le hameau)
- **Véhicules** (voiture, bicyclette, leur calèche)




- Non, mon amie, non, reprit **Ralph** **PER**, je ne veux point d'un tel sacrifice, je ne l'accepterai jamais. En quoi mon existence est-elle donc plus précieuse que la vôtre ? Pourquoi faut-il que vous vous imposiez un avenir odieux pour m'en donner un agréable ? Pensez-vous qu'il me fût possible d'en jouir en sentant que votre cœur ne le partage point ? Non, je ne suis point égoïste jusque-là.

Entraînement d'un modèle de reconnaissance d'entités




Entraînement d'un modèle de reconnaissance d'entités


Corpus
d'entraînement




Entraînement d'un modèle de reconnaissance d'entités




Entraînement d'un modèle de reconnaissance d'entités





Détection d'entités : Inférence



Détection d'entités : Inférence




Détection d'entités : Inférence




Architecture Transformeur
(Vaswani et al., 2017)

Détection d'entités : Inférence



Détection d'entités : Inférence




Plongement vectoriel




Détection d'entités : Inférence

- Non, mon amie, non, reprit Ralph, je ne veux point d'un tel sacrifice, je ne l'accepterai jamais. En quoi mon existence est-elle donc plus précieuse que la vôtre ? pourquoi faut-il que vous vous imposiez un avenir odieux pour m'en donner un agréable ? Pensez-vous qu'il me fût possible d'en jouir en sentant que votre cœur ne le partage point ? Non, je ne suis point égoïste jusque-là.




-	[0.29, -0.05, -0.02, -0.54, 0.32, ...]
Non	[0.12, -0.73, 0.08, -0.76, 0.15, ...]
,	[0.19, -0.75, 0.02, 0.06, -0.58, ...]
mon	[0.2, -0.93, 0.29, -0.66, -0.07, ...]
amie	[-0.15, -0.12, 0.1, -0.24, -0.38, ...]
,	[0.26, -0.4, 0.19, 0.08, -0.18, ...]
non	[0.01, -0.22, -0.17, -0.56, 0.01, ...]
,	[0.11, -0.85, 0.13, 0.05, -0.41, ...]
reprit	[0.04, 0.45, 0.07, -0.43, -0.15, ...]
Ralph	[0.51, -0.39, -0.32, 0.0, 0.15, ...]
,	[0.04, -0.49, 0.2, -0.26, -0.37, ...]
je	[0.22, -0.96, 0.08, -0.42, 0.18, ...]
ne	[-0.01, -0.34, 0.02, -0.06, -0.01, ...]
veux	[0.08, 0.01, 0.58, -0.01, -0.28, ...]
point	[0.18, -0.37, -0.3, -0.12, 0.03, ...]
d'	[0.22, -0.36, 0.18, -0.24, 0.12, ...]
un	[0.16, -0.31, 0.19, -0.14, 0.28, ...]
tel	[-0.25, -0.68, -0.11, -0.28, -0.11, ...]
sacrifice	[0.16, 0.27, -0.34, 0.12, 0.21, ...]




Modèle de reconnaissance d'entités

Détection d'entités : Inférence

- Non, mon amie, non, reprit Ralph, je ne veux point d'un tel sacrifice, je ne l'accepterai jamais. En quoi mon existence est-elle donc plus précieuse que la vôtre ? pourquoi faut-il que vous vous imposiez un avenir odieux pour m'en donner un agréable ? Pensez-vous qu'il me fût possible d'en jouir en sentant que votre cœur ne le partage point ? Non, je ne suis point égoïste jusque-là.



-	[0.29, -0.05, -0.02, -0.54, 0.32, ...]
Non	[0.12, -0.73, 0.08, -0.76, 0.15, ...]
,	[0.19, -0.75, 0.02, 0.06, -0.58, ...]
mon	[0.2, -0.93, 0.29, -0.66, -0.07, ...]
amie	[-0.15, -0.12, 0.1, -0.24, -0.38, ...]
,	[0.26, -0.4, 0.19, 0.08, -0.18, ...]
non	[0.01, -0.22, -0.17, -0.56, 0.01, ...]
,	[0.11, -0.85, 0.13, 0.05, -0.41, ...]
reprit	[0.04, 0.45, 0.07, -0.43, -0.15, ...]
Ralph	[0.51, -0.39, -0.32, 0.0, 0.15, ...]
,	[0.04, -0.49, 0.2, -0.26, -0.37, ...]
je	[0.22, -0.96, 0.08, -0.42, 0.18, ...]
ne	[-0.01, -0.34, 0.02, -0.06, -0.01, ...]
veux	[0.08, 0.01, 0.58, -0.01, -0.28, ...]
point	[0.18, -0.37, -0.3, -0.12, 0.03, ...]
d'	[0.22, -0.36, 0.18, -0.24, 0.12, ...]
un	[0.16, -0.31, 0.19, -0.14, 0.28, ...]
tel	[-0.25, -0.68, -0.11, -0.28, -0.11, ...]
sacrifice	[0.16, 0.27, -0.34, 0.12, 0.21, ...]



Modèle de reconnaissance d'entités

ID	Début	Fin	Mention	Type	Confiance
#0	3	3	mon	PER	99.80%
#1	3	4	mon amie	PER	98.11%
#2	9	9	ralph	PER	99.75%
#3	11	11	je	PER	99.99%
#4	20	20	je	PER	99.99%
#5	28	28	mon	PER	99.88%
#6	36	36	vôtre	PER	98.13%
#7	42	42	vous	PER	99.94%
#8	49	49	m'	PER	99.60%
#9	56	56	-vous	PER	99.86%
#10	59	59	me	PER	98.19%
#11	68	68	votre	PER	99.66%
#12	77	77	je	PER	99.99%

Détection d'entités : Inférence

- Non, mon amie, non, reprit **Ralph** **PER**, je ne veux point d'un tel sacrifice, je ne l'accepterai jamais. En quoi mon existence est-elle donc plus précieuse que la vôtre ? pourquoi faut-il que vous vous imposiez un avenir odieux pour m'en donner un agréable ? Pensez-vous qu'il me fût possible d'en jouir en sentant que votre cœur ne le partage point ? Non, je ne suis point égoïste jusque-là.

`</> View Code` 0.9s ✓ `Cached example`

`Maximize`

- Non, 1 0 mon amie , non, reprit 2 Ralph , 3 je ne veux point d'un tel sacrifice, 4 je ne l'accepterai jamais. En quoi 5 mon existence est-elle donc plus précieuse que la 6 vôtre ? pourquoi faut-il que 7 vous vous imposiez un avenir odieux pour 8 m' en donner un agréable ? Pensez9 -vous qu'il 10 me fût possible d'en jouir en sentant que 11 votre cœur ne le partage point ? Non, 12 je ne suis point égoïste jusque-là.

tion	Type	Confiance
on	PER	99.80%
amie	PER	98.11%
ph	PER	99.75%
e	PER	99.99%
e	PER	99.99%
on	PER	99.88%
tre	PER	98.13%
us	PER	99.94%
n'	PER	99.60%
ous	PER	99.86%
ne	PER	98.19%
tre	PER	99.66%
e	PER	99.99%

Détections d'entités

Texte
français

Chaîne de traitement
BookNLP-fr

Fonctions Principales

1. Détection d'entités
2. Résolution de la coréférence
3. Extraction des attributs des personnages

ID	Début	Fin	Mention	Type	Confiance
#0	3	3	mon	PER	99.80%
#1	3	4	mon amie	PER	98.11%
#2	9	9	ralph	PER	99.75%
#3	11	11	je	PER	99.99%
#4	20	20	je	PER	99.99%
#5	28	28	mon	PER	99.88%
#6	36	36	vôtre	PER	98.13%
#7	42	42	vous	PER	99.94%
#8	49	49	m'	PER	99.60%
#9	56	56	-vous	PER	99.86%
#10	59	59	me	PER	98.19%
#11	68	68	votre	PER	99.66%
#12	77	77	je	PER	99.99%

Résolution de la coréférence

Texte
français

Chaîne de traitement
BookNLP-fr

Fonctions Principales

1. Détection d'entités
2. Résolution de la coréférence
3. Extraction des attributs des personnages

ID	Début	Fin	Mention	Type	Confiance
#0	3	4	mon amie	PER	98.11%
#1	3	3	mon	PER	99.80%
#2	9	9	Ralph	PER	99.75%
#3	11	11	je	PER	99.99%
#4	20	20	je	PER	99.99%
#5	28	28	mon	PER	99.88%
#6	36	36	vôtre	PER	98.13%
#7	42	42	vous	PER	99.94%
#8	49	49	m'	PER	99.60%
#9	56	56	-vous	PER	99.86%
#10	59	59	me	PER	98.19%
#11	68	68	votre	PER	99.66%
#12	77	77	je	PER	99.99%

Objectif de la résolution de la corréférence


Texte
français

- Non, 1 0 mon amie , non, reprit 2 Ralph , 3 je ne veux point d'un tel sacrifice, 4 je ne l'accepterai jamais. En quoi 5 mon existence est-elle donc plus précieuse que la 6 vôtre ? pourquoi faut-il que 7 vous vous imposiez un avenir odieux pour 8 m' en donner un agréable ? Pensez 9 -vous qu'il 10 me fût possible d'en jouir en sentant que 11 votre cœur ne le partage point ? Non, 12 je ne suis point égoïste jusque-là.

- Non, 1 0 mon amie , non, reprit 0 Ralph , 0 je ne veux point d'un tel sacrifice, 0 je ne l'accepterai jamais. En quoi 0 mon existence est-elle donc plus précieuse que la 1 vôtre ? pourquoi faut-il que 1 vous vous imposiez un avenir odieux pour 0 m' en donner un agréable ? Pensez 1 -vous qu'il 0 me fût possible d'en jouir en sentant que 1 votre cœur ne le partage point ? Non, 0 je ne suis point égoïste jusque-là.

ent	Type	Confiance
n amie	PER	98.11%
mon	PER	99.80%
Ralph	PER	99.75%
je	PER	99.99%
je	PER	99.99%
mon	PER	99.88%
vôtre	PER	98.13%
vous	PER	99.94%
m'	PER	99.60%
-vous	PER	99.86%
me	PER	98.19%
otre	PER	99.66%
je	PER	99.99%

Modèle de résolution de la coréférence



Modèle de résolution de la coréférence

Plongement vectoriel des mentions

Liste de
mentions

Plongement
vectoriel

ID	Mention	Vecteur (1024 dimensions)
#0	mon	[0.29, -0.05, -0.02, -0.54, 0.32, ...]
#1	mon amie	[0.12, -0.73, 0.08, -0.76, 0.15, ...]
#2	ralph	[0.19, -0.75, 0.02, 0.06, -0.58, ...]
#3	je	[0.2, -0.93, 0.29, -0.66, -0.07, ...]
#4	je	[-0.15, -0.12, 0.1, -0.24, -0.38, ...]
#5	mon	[0.26, -0.4, 0.19, 0.08, -0.18, ...]
#6	vôtre	[0.01, -0.22, -0.17, -0.56, 0.01, ...]
#7	vous	[0.11, -0.85, 0.13, 0.05, -0.41, ...]
#8	m'	[0.04, 0.45, 0.07, -0.43, -0.15, ...]
#9	-vous	[0.51, -0.39, -0.32, 0.0, 0.15, ...]
#10	me	[0.04, -0.49, 0.2, -0.26, -0.37, ...]
#11	votre	[0.22, -0.96, 0.08, -0.42, 0.18, ...]
#12	je	[-0.01, -0.34, 0.02, -0.06, -0.01, ...]


Résolution de la coréférence : modèle paires de mentions

Liste de mentions

Plongement vectoriel

ID	Mention	Vecteur (1024 dimensions)
#0	mon	[0.29, -0.05, -0.02, -0.54, 0.32, ...]
#1	mon amie	[0.12, -0.73, 0.08, -0.76, 0.15, ...]
#2	ralph	[0.19, -0.75, 0.02, 0.06, -0.58, ...]
#3	je	[0.2, -0.93, 0.29, -0.66, -0.07, ...]
#4	je	[-0.15, -0.12, 0.1, -0.24, -0.38, ...]
#5	mon	[0.26, -0.4, 0.19, 0.08, -0.18, ...]
#6	vôtre	[0.01, -0.22, -0.17, -0.56, 0.01, ...]
#7	vous	[0.11, -0.85, 0.13, 0.05, -0.41, ...]
#8	m'	[0.04, 0.45, 0.07, -0.43, -0.15, ...]
#9	-vous	[0.51, -0.39, -0.32, 0.0, 0.15, ...]
#10	me	[0.04, -0.49, 0.2, -0.26, -0.37, ...]
#11	votre	[0.22, -0.96, 0.08, -0.42, 0.18, ...]
#12	je	[-0.01, -0.34, 0.02, -0.06, -0.01, ...]


Paire de mentions



Score de coréférence

< 0.5 : Non coréférent
> 0.5 : Coréférent

Résolution de la corréférence : Paires de Mentions




Résolution de la coréférence : Paires de Mentions

Liste de mentions

Plongement vectoriel

ID	Mention	Vecteur (1024 dimensions)
#0	mon	[0.29, -0.05, -0.02, -0.54, 0.32, ...]
#1	mon amie	[0.12, -0.73, 0.08, -0.76, 0.15, ...]
#2	ralph	[0.19, -0.75, 0.02, 0.06, -0.58, ...]
#3	je	[0.2, -0.93, 0.29, -0.66, -0.07, ...]
#4	je	[-0.15, -0.12, 0.1, -0.24, -0.38, ...]
#5	mon	[0.26, -0.4, 0.19, 0.08, -0.18, ...]
#6	vôtre	[0.01, -0.22, -0.17, -0.56, 0.01, ...]
#7	vous	[0.11, -0.85, 0.13, 0.05, -0.41, ...]
#8	m'	[0.04, 0.45, 0.07, -0.43, -0.15, ...]
#9	-vous	[0.51, -0.39, -0.32, 0.0, 0.15, ...]
#10	me	[0.04, -0.49, 0.2, -0.26, -0.37, ...]
#11	votre	[0.22, -0.96, 0.08, -0.42, 0.18, ...]
#12	je	[-0.01, -0.34, 0.02, -0.06, -0.01, ...]



Score("mon", "mon amie")

= 0.04

< 0.5 : Non coréférent

	mon	mon amie	ralph	je	je	mon	vôtre	vous	m'	-vous	me	votre
mon amie												
ralph												
je												
je												
mon												
vôtre												
vous												
m'												
-vous												
me												
votre												
je												


Matrice de coréférence

Résolution de la coréférence : Paires de Mentions

Liste de mentions

Plongement vectoriel

ID	Mention	Vecteur (1024 dimensions)
#0	mon	[0.29, -0.05, -0.02, -0.54, 0.32, ...]
#1	mon amie	[0.12, -0.73, 0.08, -0.76, 0.15, ...]
#2	ralph	[0.19, -0.75, 0.02, 0.06, -0.58, ...]
#3	je	[0.2, -0.93, 0.29, -0.66, -0.07, ...]
#4	je	[-0.15, -0.12, 0.1, -0.24, -0.38, ...]
#5	mon	[0.26, -0.4, 0.19, 0.08, -0.18, ...]
#6	vôtre	[0.01, -0.22, -0.17, -0.56, 0.01, ...]
#7	vous	[0.11, -0.85, 0.13, 0.05, -0.41, ...]
#8	m'	[0.04, 0.45, 0.07, -0.43, -0.15, ...]
#9	-vous	[0.51, -0.39, -0.32, 0.0, 0.15, ...]
#10	me	[0.04, -0.49, 0.2, -0.26, -0.37, ...]
#11	votre	[0.22, -0.96, 0.08, -0.42, 0.18, ...]
#12	je	[-0.01, -0.34, 0.02, -0.06, -0.01, ...]



Score("mon", "mon amie")
= 0.04
< 0.5 : Non coréférent

	mon	mon amie	ralph	je	je	mon	vôtre	vous	m'	-vous	me	votre
mon amie	0.04											
ralph												
je												
je												
mon												
vôtre												
vous												
m'												
-vous												
me												
votre												
je												


Matrice de coréférence

Résolution de la coréférence : Paires de Mentions

Liste de mentions

Plongement vectoriel

ID	Mention	Vecteur (1024 dimensions)
#0	mon	[0.29, -0.05, -0.02, -0.54, 0.32, ...]
#1	mon amie	[0.12, -0.73, 0.08, -0.76, 0.15, ...]
#2	ralph	[0.19, -0.75, 0.02, 0.06, -0.58, ...]
#3	je	[0.2, -0.93, 0.29, -0.66, -0.07, ...]
#4	je	[-0.15, -0.12, 0.1, -0.24, -0.38, ...]
#5	mon	[0.26, -0.4, 0.19, 0.08, -0.18, ...]
#6	vôtre	[0.01, -0.22, -0.17, -0.56, 0.01, ...]
#7	vous	[0.11, -0.85, 0.13, 0.05, -0.41, ...]
#8	m'	[0.04, 0.45, 0.07, -0.43, -0.15, ...]
#9	-vous	[0.51, -0.39, -0.32, 0.0, 0.15, ...]
#10	me	[0.04, -0.49, 0.2, -0.26, -0.37, ...]
#11	votre	[0.22, -0.96, 0.08, -0.42, 0.18, ...]
#12	je	[-0.01, -0.34, 0.02, -0.06, -0.01, ...]



	mon	mon amie	ralph	je	je	mon	vôtre	vous	m'	-vous	me	votre
mon amie	0.04											
ralph	0.88	0.18										
je												
je												
mon												
vôtre												
vous												
m'												
-vous												
me												
votre												
je												


Matrice de coréférence

Résolution de la coréférence : Paires de Mentions

Liste de mentions

Plongement vectoriel

ID	Mention	Vecteur (1024 dimensions)
#0	mon	[0.29, -0.05, -0.02, -0.54, 0.32, ...]
#1	mon amie	[0.12, -0.73, 0.08, -0.76, 0.15, ...]
#2	ralph	[0.19, -0.75, 0.02, 0.06, -0.58, ...]
#3	je	[0.2, -0.93, 0.29, -0.66, -0.07, ...]
#4	je	[-0.15, -0.12, 0.1, -0.24, -0.38, ...]
#5	mon	[0.26, -0.4, 0.19, 0.08, -0.18, ...]
#6	vôtre	[0.01, -0.22, -0.17, -0.56, 0.01, ...]
#7	vous	[0.11, -0.85, 0.13, 0.05, -0.41, ...]
#8	m'	[0.04, 0.45, 0.07, -0.43, -0.15, ...]
#9	-vous	[0.51, -0.39, -0.32, 0.0, 0.15, ...]
#10	me	[0.04, -0.49, 0.2, -0.26, -0.37, ...]
#11	votre	[0.22, -0.96, 0.08, -0.42, 0.18, ...]
#12	je	[-0.01, -0.34, 0.02, -0.06, -0.01, ...]



	mon	mon amie	ralph	je	je	mon	vôtre	vous	m'	-vous	me	votre
mon amie	0.04											
ralph	0.88	0.18										
je	0.99	0.06	0.93									
je	1.00	0.05	0.96	1.00								
mon	1.00	0.01	0.85	1.00	1.00							
vôtre	0.00	0.98	0.36	0.00	0.00	0.00						
vous	0.00	0.93	0.20	0.00	0.00	0.00	1.00					
m'	0.99	0.07	0.88	1.00	0.96	1.00	0.00	0.00				
-vous	0.01	0.92	0.30	0.00	0.02	0.00	0.99	0.96	0.02			
me	0.94	0.23	0.67	0.96	0.84	0.98	0.02	0.00	0.93	0.00		
votre	0.00	0.96	0.35	0.00	0.00	0.00	1.00	0.99	0.00	1.00	0.00	
je	0.98	0.16	0.89	0.99	0.96	0.95	0.01	0.02	0.95	0.01	0.99	0.09


Matrice de coréférence

Antécédent le plus probable

Liste de mentions

Plongement vectoriel

ID	Mention	Vecteur (1024 dimensions)
#0	mon	[0.29, -0.05, -0.02, -0.54, 0.32, ...]
#1	mon amie	[0.12, -0.73, 0.08, -0.76, 0.15, ...]
#2	ralph	[0.19, -0.75, 0.02, 0.06, -0.58, ...]
#3	je	[0.2, -0.93, 0.29, -0.66, -0.07, ...]
#4	je	[-0.15, -0.12, 0.1, -0.24, -0.38, ...]
#5	mon	[0.26, -0.4, 0.19, 0.08, -0.18, ...]
#6	vôtre	[0.01, -0.22, -0.17, -0.56, 0.01, ...]
#7	vous	[0.11, -0.85, 0.13, 0.05, -0.41, ...]
#8	m'	[0.04, 0.45, 0.07, -0.43, -0.15, ...]
#9	-vous	[0.51, -0.39, -0.32, 0.0, 0.15, ...]
#10	me	[0.04, -0.49, 0.2, -0.26, -0.37, ...]
#11	votre	[0.22, -0.96, 0.08, -0.42, 0.18, ...]
#12	je	[-0.01, -0.34, 0.02, -0.06, -0.01, ...]



	mon	mon amie	ralph	je	je	mon	vôtre	vous	m'	-vous	me	votre
mon amie												
ralph	0.88											
je	0.99											
je				1.00								
mon				1.00								
vôtre		0.98										
vous							1.00					
m'					1.00							
-vous							0.99					
me						0.98						
votre										1.00		
je											0.99	


Matrice de corréférence

Clustering des mentions coréférentes

Liste de mentions

Plongement vectoriel

ID	Mention	Vecteur (1024 dimensions)
#0	mon	[0.29, -0.05, -0.02, -0.54, 0.32, ...]
#1	mon amie	[0.12, -0.73, 0.08, -0.76, 0.15, ...]
#2	ralph	[0.19, -0.75, 0.02, 0.06, -0.58, ...]
#3	je	[0.2, -0.93, 0.29, -0.66, -0.07, ...]
#4	je	[-0.15, -0.12, 0.1, -0.24, -0.38, ...]
#5	mon	[0.26, -0.4, 0.19, 0.08, -0.18, ...]
#6	vôtre	[0.01, -0.22, -0.17, -0.56, 0.01, ...]
#7	vous	[0.11, -0.85, 0.13, 0.05, -0.41, ...]
#8	m'	[0.04, 0.45, 0.07, -0.43, -0.15, ...]
#9	-vous	[0.51, -0.39, -0.32, 0.0, 0.15, ...]
#10	me	[0.04, -0.49, 0.2, -0.26, -0.37, ...]
#11	votre	[0.22, -0.96, 0.08, -0.42, 0.18, ...]
#12	je	[-0.01, -0.34, 0.02, -0.06, -0.01, ...]



	mon	mon amie	ralph	je	je	mon	vôtre	vous	m'	-vous	me	votre
mon												
amie												
ralph	0.88											
je	0.99											
je												
mon												
vôtre		0.98										
vous												
m'												
-vous												
me												
votre												
je												


Matrice de coréférence

Clustering des mentions coréférentes

Liste de mentions

Plongement vectoriel

ID	Mention	Vecteur (1024 dimensions)
#0	mon	[0.29, -0.05, -0.02, -0.54, 0.32, ...]
#1	mon amie	[0.12, -0.73, 0.08, -0.76, 0.15, ...]
#2	ralph	[0.19, -0.75, 0.02, 0.06, -0.58, ...]
#3	je	[0.2, -0.93, 0.29, -0.66, -0.07, ...]
#4	je	[-0.15, -0.12, 0.1, -0.24, -0.38, ...]
#5	mon	[0.26, -0.4, 0.19, 0.08, -0.18, ...]
#6	vôtre	[0.01, -0.22, -0.17, -0.56, 0.01, ...]
#7	vous	[0.11, -0.85, 0.13, 0.05, -0.41, ...]
#8	m'	[0.04, 0.45, 0.07, -0.43, -0.15, ...]
#9	-vous	[0.51, -0.39, -0.32, 0.0, 0.15, ...]
#10	me	[0.04, -0.49, 0.2, -0.26, -0.37, ...]
#11	votre	[0.22, -0.96, 0.08, -0.42, 0.18, ...]
#12	je	[-0.01, -0.34, 0.02, -0.06, -0.01, ...]



	mon	mon amie	ralph	je	je	mon	vôtre	vous	m'	-vous	me	votre
mon amie												
ralph	0.88											
je	0.99											
je				1.00								
mon				1.00								
vôtre		0.98										
vous							1.00					
m'					1.00							
-vous							0.99					
me						0.98						
votre									1.00			
je											0.99	


Matrice de coréférence

Clustering des mentions coréférentes

Liste de mentions

Plongement vectoriel

ID	Mention	Vecteur (1024 dimensions)
#0	mon	[0.29, -0.05, -0.02, -0.54, 0.32, ...]
#1	mon amie	[0.12, -0.73, 0.08, -0.76, 0.15, ...]
#2	ralph	[0.19, -0.75, 0.02, 0.06, -0.58, ...]
#3	je	[0.2, -0.93, 0.29, -0.66, -0.07, ...]
#4	je	[-0.15, -0.12, 0.1, -0.24, -0.38, ...]
#5	mon	[0.26, -0.4, 0.19, 0.08, -0.18, ...]
#6	vôtre	[0.01, -0.22, -0.17, -0.56, 0.01, ...]
#7	vous	[0.11, -0.85, 0.13, 0.05, -0.41, ...]
#8	m'	[0.04, 0.45, 0.07, -0.43, -0.15, ...]
#9	-vous	[0.51, -0.39, -0.32, 0.0, 0.15, ...]
#10	me	[0.04, -0.49, 0.2, -0.26, -0.37, ...]
#11	votre	[0.22, -0.96, 0.08, -0.42, 0.18, ...]
#12	je	[-0.01, -0.34, 0.02, -0.06, -0.01, ...]




	mon	mon amie	ralph	je	je	mon	vôtre	vous	m'	-vous	me	votre
mon amie												
ralph	0.88											
je	0.99											
je				1.00								
mon				1.00								
vôtre		0.98										
vous							1.00					
m'					1.00							
-vous							0.99					
me						0.98						
votre										1.00		
je											0.99	

Matrice de coréférence


Clustering des mentions coréférentes

Liste de
mentions

Plongement
vectoriel



ID	Mention	Vecteur (1024 dimensions)
#0	mon	[0.29, -0.05, -0.02, -0.54, 0.32, ...]
#1	mon amie	[0.12, -0.73, 0.08, -0.76, 0.15, ...]
#2	ralph	[0.19, -0.75, 0.02, 0.06, -0.58, ...]
#3	je	[0.2, -0.93, 0.29, -0.66, -0.07, ...]
#4	je	[-0.15, -0.12, 0.1, -0.24, -0.38, ...]
#5	mon	[0.26, -0.4, 0.19, 0.08, -0.18, ...]
#6	vôtre	[0.01, -0.22, -0.17, -0.56, 0.01, ...]
#7	vous	[0.11, -0.85, 0.13, 0.05, -0.41, ...]
#8	m'	[0.04, 0.45, 0.07, -0.43, -0.15, ...]
#9	-vous	[0.51, -0.39, -0.32, 0.0, 0.15, ...]
#10	me	[0.04, -0.49, 0.2, -0.26, -0.37, ...]
#11	votre	[0.22, -0.96, 0.08, -0.42, 0.18, ...]
#12	je	[-0.01, -0.34, 0.02, -0.06, -0.01, ...]




Matrice de
coréférence

Extraction des chaînes de corréférence

Liste de mentions


Plongement vectoriel

Paire de mentions



Modèle de résolution de la corréférence

Matrice de corréférence




ID	Mention	Vecteur (1024 dimensions)
#0	mon	[0.29, -0.05, -0.02, -0.54, 0.32, ...]
#1	mon amie	[0.12, -0.73, 0.08, -0.76, 0.15, ...]
#2	ralph	[0.19, -0.75, 0.02, 0.06, -0.58, ...]
#3	je	[0.2, -0.93, 0.29, -0.66, -0.07, ...]
#4	je	[-0.15, -0.12, 0.1, -0.24, -0.38, ...]
#5	mon	[0.26, -0.4, 0.19, 0.08, -0.18, ...]
#6	vôtre	[0.01, -0.22, -0.17, -0.56, 0.01, ...]
#7	vous	[0.11, -0.85, 0.13, 0.05, -0.41, ...]
#8	m'	[0.04, 0.45, 0.07, -0.43, -0.15, ...]
#9	-vous	[0.51, -0.39, -0.32, 0.0, 0.15, ...]
#10	me	[0.04, -0.49, 0.2, -0.26, -0.37, ...]
#11	votre	[0.22, -0.96, 0.08, -0.42, 0.18, ...]
#12	je	[-0.01, -0.34, 0.02, -0.06, -0.01, ...]

Extraction des chaînes de corréférence

- 0: "mon", "Ralph", "je", "je", "mon", "m", "me", "je"
- 1: "mon amie", "vôtre", "vous", "-vous", "votre"

- Non, 1 0 mon amie , non, reprit 0 Ralph , 0 je ne veux point d'un tel sacrifice, 0 je ne l'accepterai jamais. En quoi 0 mon existence est-elle donc plus précieuse que la 1 votre ? pourquoi faut-il que 1 vous vous imposiez un avenir odieux pour 0 m' en donner un agréable ? Pensez 1 -vous qu'il 0 me fût possible d'en jouir en sentant que 1 votre cœur ne le partage point ? Non, 0 je ne suis point égoïste jusque-là.

Résolution de la coréférence




Extraction des attributs des personnages



Fonctions Principales

1. Détection d'entités
2. Résolution de la coréférence
3. Extraction des attributs des personnages

Extraction des attributs des personnages




- Genre de la chaîne (masculin, féminin, N/A)
- Nombre de la chaîne (singulier, pluriel, N/A)
- Verbes dont le personnage est le sujet
 - Mobilité
 - Communication
 - Actions
 - Perceptions
 - Possession
- Verbes dont le personnage est l'objet
- Qualificatifs
 - Profession
 - Traits physiques
 - Traits psychologiques
 - Âge
 - Sentiments / Émotions
- Possessifs
 - Parties du corps
 - Relations sociales
 - Objets et Vêtements
 - Traits de personnalité


Sorties de la chaîne de traitement




Exemples d'applications



Exemples d'applications



Exemples d'applications




Exemples d'applications

- Entités
 - Personnages
 - Temporelles
 - Infrastructures
 - Géographiques
 - Géopolitiques
 - Véhicules
- Chaînes de coréférence
- Attributs des personnages
 - Genre
 - Nombre
 - Verbes sujet
 - Verbes objet
 - Qualificatifs
 - Possessifs

Corpus Chapitres
2942 romans
(1811-2020)

Chaîne de traitement
BookNLP-fr

Date de Publication
+
Genre de l'auteur-ice



Évolution de la proportion de mentions de personnages féminins dans les romans en fonction du genre de l'auteur-ice

Exemples d'applications

Corpus Chapitres
2942 romans
(1811-2020)

Chaîne de traitement
BookNLP-fr

- Entités
 - Personnages
 - Temporelles
 - Infrastructures
 - Géographiques
 - Géopolitiques
 - Véhicules
- Chaînes de coréférence
- Attributs des personnages
 - Genre
 - Nombre
 - **Verbes sujet**
 - Verbes objet
 - Qualificatifs
 - Possessifs

Gender Bias in French Literature

Laurine Vianne^{1,2,*}, Yoann Dupont^{1,3,*} and Jean Barré^{1,4}

¹ Lattice (Langues, Textes, Traitements informatiques, Cognition), 1 rue Maurice Arnoux, Montrouge, 92049, France

² Université Paris Cité, 85 boulevard Saint-Germain, Paris, 75006, France

³ Université Sorbonne Nouvelle, 17 rue de la Sorbonne, Paris, 75230, France

⁴ École nationale supérieure - Université PSL, 45 rue d'Ulm, Paris, 75005, France

Abstract

This study delves into the representation of gender in French literature from 1800 to the present, aiming to assess the prevalence of gender stereotypes in the description of fictional characters. By employing an annotated corpus and statistical modeling techniques, the research explores how authors perpetuated gender biases while shaping characters and narratives. The findings reveal significant linguistic patterns that reinforce gender norms, with women being characterized by emotional and physical attributes, while men are associated with action and agency.

Keywords

french literature, bias, gender, automatic classification,


Étude sur les représentations genrées
dans la littérature française

Exemples d'applications

Corpus Chapitres
2942 romans
(1811-2020)

Chaîne de traitement
BookNLP-fr

- Entités
 - Personnages
 - Temporelles
 - Infrastructures
 - Géographiques
 - Géopolitiques
 - Véhicules
- Chaînes de coréférence
- Attributs des personnages
 - Genre
 - Nombre
 - **Verbes sujet**
 - Verbes objet
 - Qualificatifs
 - Possessifs



Verbes de communication

Masculin +

Féminin +


Étude sur les représentations genrées
dans la littérature française

Exemples d'applications

Corpus Chapitres
2942 romans
(1811-2020)

Chaîne de traitement
BookNLP-fr

- Entités
 - Personnages
 - Temporelles
 - Infrastructures
 - Géographiques
 - Géopolitiques
 - Véhicules
- Chaînes de coréférence
- Attributs des personnages
 - **Genre**
 - Nombre
 - Verbes sujet
 - Verbes objet
 - **Qualificatifs**
 - Possessifs




Adjectifs Traits Physiques

Masculin +


Féminin +

Étude sur les représentations genrées
dans la littérature française


Exemples d'applications



Une chaîne de traitement en évolution



Objectif : rendre *BookNLP-fr* accessible au plus grand nombre



Démonstration prise en main de la librairie *BookNLP-fr*

The screenshot displays a Jupyter Notebook titled 'demonstration_booknlp_fr.ipynb' within the Visual Studio Code editor. The notebook is organized into four sections, each with a title and a description of the number of hidden cells:

- Initialisation** (2 cells hidden)
- 1) Installer la librairie**
- 2) Charger la librairie et les modèles**
- 3) Charger un fichier texte (.txt)** (1 cell hidden)
- 4) Tokenisation du texte** (1 cell hidden)

The code visible in the notebook includes the installation of the library and the loading of models:

```
! pip install booknlp_fr -U
```




```
from booknlp_fr import (load_text_file, clean_text, load_spacy_model, generate_tokens_df, load_mentions_detection_model, load_tokenizer_and_embedding_model,
                        get_embedding_tensor_from_tokens_df, generate_entities_df, add_features_to_entities, load_coreference_resolution_model, perform_coreference,
                        extract_attributes, generate_characters_dict)

spacy_model, mentions_detection_model, coreference_resolution_model, tokenizer, embedding_model = load_models()
[1]
```

The interface also shows a sidebar with various tools like Project, Commit, Structure, Python Console, TODO, Hugging Face, Jupyter, Python Packages, Services, Terminal, Problems, and Git. The bottom status bar indicates the file encoding (UTF-8), indentation (4 spaces), and the Python version (3.10).

Notebook Google Colab - Accessible en ligne



The screenshot shows a Google Colab notebook interface. At the top, the title bar reads 'BookNLP-fr Hands-on Tutorial Notebook.ipynb' with icons for file management, settings, and sharing. Below the title bar is a menu bar with options: 'Fichier', 'Modifier', 'Affichage', 'Insérer', 'Exécution', 'Outils', and 'Aide'. A search bar labeled 'Commandes' is on the left, and a 'Connecter T4' button is on the right. The main content area is divided into a left sidebar and a right pane. The sidebar contains icons for file explorer, search, and other functions. The right pane displays the notebook content, which includes a welcome message, a section for 'Step 1: Installing Required Libraries', and a section for 'Step 2: Loading a French Novel'. The text in the notebook is as follows:

BookNLP-fr Hands-on Tutorial

Welcome to the BookNLP-fr tutorial! This notebook will guide you through the process of analyzing a French novel using the booknlp-fr library. You'll learn how to load a novel, tokenize it, extract named entities, resolve coreferences, and analyze the main characters.

> Step 1: Installing Required Libraries

Before we begin, we need to install the necessary libraries. We'll use spaCy for tokenization and booknlp_fr for mention detection and coreference resolution.

[] ↳ 1 cellule masquée

> Step 2: Loading a French Novel

In this step, you will be importing a novel from Project Gutenberg (or any other source you would like) that will be used as an example in the rest of the notebook

You can select a book from this page: [Project Gutenberg French Books List](#)

[] ↳ 1 cellule masquée

> Step 3: Preprocessing the Text

Merci de votre attention