

TP d'introduction au TAL.

Aujourd'hui nous allons faire de la réduction de dimension.

Nous allons faire de la réduction de dimension avec des méthodes linéaires et non linéaires.

YOUR CODE HERE marque des endroits où vous devez coder. Vous pouvez bien sûr coder ailleurs aussi.

0. Récupérez les données du TP ainsi que le code sur Github.

I. Représentation de documents

Le dossier *pages* contient des textes bruts de pages wikipédia en français correspondant à des pays et des capitales entre autres. L'on va considérer chaque page comme un document que l'on veut représenter dans un espace pour pouvoir ensuite observer la structure de cet espace.

1. Dans le script *capitals.py* les fichiers sont lus et un vocabulaire en est extrait. A vous d'en faire une matrice de cooccurrence (terme-document).

2. Une fois la matrice créée, faites en une réduction linéaire à 2 dimension grâce à la PCA de Scikit-learn.

J'ai aussi écrit un morceau de code pour sauvegarder les réductions sous forme d'images.

3. Réduisez la même matrice en utilisant l'algorithme t-SNE de sklearn. Remarque : il y a de nombreux paramètres pour le t-SNE essayer différentes distances (euclidean et cosine, au minimum) et faites varier la perplexité.

De la structure émerge-t-elle dans les représentation en 2 dimensions ?

En pratique on réduit rarement une matrice brute sans l'avoir préalablement normalisée. Faites une normalisation tf-idf :

$$x_{ij}' = x_{ij} / \sum_j x_{ij} \times \log(D / |\{d \mid w_i \in d\}|)$$
 où x_{ij} est la fréquence du mot w_i dans le document d_j et D est le nombre total de documents.

4. 5. Réduisez la matrice normalisée avec PCA et t-SNE.

De la structure émerge-t-elle dans les représentation en 2 dimensions ?

II. Caractères

Si vous avez le temps, vous pouvez répéter ces analyses en utilisant les caractères comme unités à représenter et comme context.