



Apprentissage Supervisé

Classification de textes

Jean Barré

01 Mars 2025

ENS-PSL

Apprentissage Supervisé vs Non Supervisé

Apprentissage Supervisé vs Non Supervisé


- Apprentissage Supervisé :
 - Le modèle est entraîné sur des données étiquetées, c'est-à-dire avec des réponses connues.
 - Exemple : classifier des romans en fonction de leur sous-genres romanesques
- Apprentissage Non Supervisé :
 - Le modèle apprend sans réponses connues, en identifiant lui-même des patterns dans les données.
 - Exemple : identifier des groupes de mots fréquents dans un corpus de textes.

- Classification :
 - Le modèle attribue des catégories ou classes aux données.
 - Exemple : déterminer si un texte est de type « fiction » ou « essai ».
- Régression :
 - Le modèle prédit des valeurs continues.
 - Exemple : estimer la date approximative d'un texte à partir de caractéristiques textuelles.


4



Surentraînement vs Sous-entraînement



- Sous-entraînement :
 - Le modèle est trop simple et n'arrive pas à capturer les patterns des données.
 - Se traduit par des erreurs élevées tant sur les données d'entraînement que de test.
- Surentraînement :
 - Le modèle est trop complexe et s'adapte excessivement aux données d'entraînement.
 - Il capture le bruit et les variations spécifiques, ce qui nuit à sa capacité de généralisation.



Bias



variance tradeoff



- Mémoriser :
 - Le modèle retient les exemples spécifiques vus pendant l'apprentissage.
 - Risque de mauvaise performance sur de nouveaux exemples.
- Généraliser :
 - Le modèle extrait des patterns pertinents qui s'appliquent à des données inédites.
 - Assure une bonne performance sur des cas non vus.

- Extraire les patterns de la matrice de données X .
- Dédurre une structure capable de prédire ou d'estimer une cible Y (par exemple : le genre d'un texte, l'époque d'un document).

- Modélisation Descriptive :
 - Comprendre et résumer les informations contenues dans les données.
 - Exemple : analyser des tendances historiques ou identifier des groupes similaires.
- Modélisation Prédictive :
 - Utiliser les patterns pour faire des prédictions sur de nouvelles données.
 - Exemple : prédire l'auteur probable d'un texte non attribué.

- Données d'Entraînement :
 - Utilisées pour apprendre et entraîner le modèle.
- Données de Test :
 - Utilisées pour évaluer la performance du modèle sur des exemples non vus durant l'entraînement.

Définition

- Une fonction de mappage / correspondance h qui associe une donnée $x \in \mathcal{X}$ à une étiquette $y \in \mathcal{Y}$ l'ensemble de sortie possible.

Exemple

- $\mathcal{X}$ = ensemble de tous les documents.
- $\mathcal{Y} = \{\text{anglais, mandarin, grec, ...}\}.$

Avec

- x = un document unique.
- y = grec ancien.
- $h(x) = y$, par exemple :

$$h(\quad) = \text{grec ancien.}$$

Recherche de la meilleure approximation

- Soit $h(x)$ la fonction « vraie ». Nous ne la connaissons jamais.
- Comment trouver la meilleure approximation $\hat{h}(x)$ de $h(x)$?

Exemple de règle basée

- Si x contient des caractères dans la plage Unicode 0370-03FF :
alors $\hat{h}(x) = \text{grec}$.

Principe

- À partir de données d'entraînement sous forme de paires $\langle \mathbf{x}, y \rangle$, on apprend une fonction $\hat{h}(\mathbf{x})$ qui approxime $h(\mathbf{x})$.

Exemples de tâches de classification

- Identification de la langue : texte {anglais, mandarin, grec, ...}.
- Classification de spam : email {spam, non-spam}.
- Attribution d'auteur : texte {JK Rowling, James Joyce, ...}.
- Classification par genre : roman {policier, romance, gothique, ...}.
- Analyse des sentiments : texte {positif, négatif, neutre, mixte}.

Analyse de sentiment au niveau du document

- Déterminer si le texte complet est positif ou négatif (ou les deux/neutre) par rapport à une cible implicite.
- Exemple : critiques de films (Pang et al. 2002, Turney 2002).

Exemples de textes annotés

- Exemple négatif :
« J'ai détesté ce film. Détesté, détesté, détesté, détesté, détesté ce film. Je l'ai détesté. J'ai détesté chaque instant ridicule et insultant pour le public. J'ai détesté la sensibilité qui pensait que quelqu'un pourrait l'apprécier. »
- Exemple positif :
« ... est un film qui provoque de vrais frissons, non figuratifs, le long de ma colonne vertébrale, et c'est sans doute le fruit le plus courageux et ambitieux du génie de Coppola. »
- Sources : Roger Ebert, Apocalypse Now (positif) et North (négatif).

Définition

- Le sentiment ne mesure plus l'attitude du locuteur vis-à-vis d'une cible particulière, mais la tonalité générale (positive ou négative) qui s'en dégage.

Sentiment comme tonalité (suite)




Fig. 1 : Dodds et al. (2011) : « Temporal patterns of happiness and information in a global social network : Hedonometrics and Twitter ».

Sentiment comme tonalité (suite)




Fig. 2 : Golder et Macy (2011) : « Diurnal and Seasonal Mood Vary with Work, Sleep, and Daylength Across Diverse Cultures »

- General Inquirer (1966).
- MPQA subjectivity lexicon (Wilson et al. 2005)
http://mpqa.cs.pitt.edu/lexicons/subj_lexicon/.
- LIWC (Linguistic Inquiry and Word Count, Pennebaker 2015).
-> Mesure de l'affect positif (PA) et de l'affect négatif (NA)
- AFINN (Nielsen 2011).
- NRC Word-Emotion Association Lexicon (EmoLex), Mohammad et Turney (2013).

LIWC (Linguistic Inquiry and Word Count)

- Comprend 73 lexiques distincts, conçus pour des applications en psychologie sociale.

Positive Emotion	Negative Emotion	Insight	Inhibition	Family	Negate
appreciat*	anger*	aware*	avoid*	brother*	aren't
comfort*	bore*	believe	careful*	cousin*	cannot
great	cry	decid*	hesitat*	daughter*	didn't
happy	despair*	feel	limit*	family	neither
interest	fail*	figur*	oppos*	father*	never
joy*	fear	know	prevent*	grandf*	no
perfect*	griev*	knew	reluctan*	grandm*	nobod*
please*	hate*	means	safe*	husband	none
safe*	panic*	notice*	stop	mom	nor
terrific	suffers	recogni*	stubborn*	mother	nothing
value	terrify	sense	wait	niece*	nowhere
wow*	violent*	think	wary	wife	without

Pourquoi l'analyse de sentiment est-elle difficile ?

- Le sentiment mesure l'état privé d'un locuteur, qui est inobservable.
 - Parfois, des mots simples (ex. : love, amazing, hate, terrible) sont de bons indicateurs, mais souvent une connaissance approfondie du contexte est nécessaire.
 - Exemple :
 - « Valentine's Day is being marketed as a Date Movie. I think it's more of a First-Date Movie. If your date likes it, do not date that person again. And if you like it, there may not be a second date. »
- Roger Ebert, Valentine's Day

Principe

- À partir de données d'entraînement sous forme de paires $\langle x, y \rangle$, on apprend une fonction $\hat{h}(x)$ qui approxime la véritable fonction $h(x)$.
- « loved it ! » $\rightarrow$ positif.
- « terrible movie » $\rightarrow$ négatif.
- « not too shabby » $\rightarrow$ positif.

Composantes de $\hat{h}(x)$

- La structure formelle de la méthode d'apprentissage (ex. : Naive Bayes, régression logistique, réseau de neurones convolutionnel, etc.).
- La représentation des données.

- Utilisation uniquement des mots positifs ou négatifs issus du LIWC.
- Représentation en sac de mots (mots isolés).
- Conjonctions de mots (ngrams séquentiels, skip-ngrams, autres combinaisons non linéaires).
- Structures linguistiques de haut niveau (ex. : syntaxe).

Mot	Apocalypse Now	North
the	1	1
of	0	0
hate	0	9
genius	1	0
bravest	1	0
stupid	0	1
like	0	1

Tab. 1 : Représentation des textes par le sac de mots

- Espace de sortie : $Y = \{0, 1\}$.
- Modèle :

$$P(y = 1 \mid x, \beta) = \frac{1}{1 + \exp\left(-\sum_{i=1}^F x_i \beta_i\right)}$$




Fig. 3 : Régression Logistique

Vecteur de caractéristiques et coefficients

Exemple de caractéristiques extraites
Caractéristiques (Valeurs)

Mot	Valeur
the	0
and	0
bravest	0
love	0
loved	0
genius	0
not	0
fruit	1
BIAS	1

Coefficients (β)

Mot	β
the	0.01
and	0.03
bravest	1.4
love	3.1
loved	1.2
genius	0.5
not	-3.0
fruit	-0.8
BIAS	-0.1

Exemple illustratif de vecteur de caractéristiques et des coefficients pour la régression logistique.

- La régression logistique est un classificateur discriminatif.
- Elle n'assume pas l'indépendance des caractéristiques.
- Sa force réside dans la possibilité d'utiliser des caractéristiques riches et expressives sans la contrainte d'indépendance.

Les caractéristiques sont l'endroit où vous pouvez encoder votre propre compréhension du problème du problème.

- Unigrams : ex. like.
- Bigrams : ex. not like, et n-grammes d'ordre supérieur.
- Préfixes : mots commençant par, par exemple, in-.
- Présence dans un dictionnaire de sentiment positif : indique si le mot figure dans une liste prédéfinie.

Exemple de caractéristiques extraites

Coefficients (β)

Comment avoir de bonnes valeurs
de β ?

Mot	β
the	0.01
and	0.03
bravest	1.4
love	3.1
loved	1.2
genius	0.5
not	-3.0
fruit	-0.8
BIAS	-0.1

- Pour l'ensemble des données d'entraînement, on souhaite que la probabilité du label vrai y pour chaque exemple x soit élevée.
- La vraisemblance conditionnelle s'exprime par :

$$\prod_{i=1}^N P(y_i | x_i, \beta)$$

- L'objectif est de choisir les paramètres β qui maximisent cette probabilité.

- Considérons un exemple avec des caractéristiques telles que love et loved :

Exemple	love	loved	$a = \sum x_i \beta_i$	$\exp(-a)$	$P(y = 1 x, \beta)$
x_1	1	0	3.0	0.05	95.2%
x_2	1	1	4.2	0.015	98.5%
x_3	0	0	-0.1	1.11	41.5%

- Maximiser la vraisemblance revient à maximiser la log-vraisemblance :

$$\arg \max_{\beta} \prod_{i=1}^N P(y_i | x_i, \beta) = \arg \max_{\beta} \sum_{i=1}^N \log P(y_i | x_i, \beta)$$

- On définit alors la fonction objective :

$$\mathcal{L}(\beta) = \sum_{i=1}^N \log P(y_i | x_i, \beta)$$

- La maximisation de $\mathcal{L}(\beta)$ permet d'obtenir les meilleurs paramètres.

- Pour maximiser $\mathcal{L}(\beta)$, on utilise la descente de gradient.
- Le gradient de la log-vraisemblance est donné par :

$$\nabla \mathcal{L}(\beta) = \sum_{\langle x, y \rangle} (y - \hat{p}(x)) x_i$$

- Exemples :
 - Si $y = 1$ et $\hat{p}(x) = 0.99$, la mise à jour des poids sera faible.
 - Si $y = 1$ et $\hat{p}(x) = 0$, la mise à jour sera importante.
- La descente de gradient stochastique met à jour β après chaque point de données.

- Lors du calcul de $P(y | x)$ ou du gradient, il suffit de considérer les caractéristiques non nulles.
- Ceci rend particulièrement utile l'utilisation de valeurs binaires et d'une représentation parcimonieuse.
- La régression logistique s'exprime ainsi :

$$P(y = 1 | x, \beta) = \frac{1}{1 + \exp\left(-\sum_{i=1}^F x_i \beta_i\right)}$$

- De nombreuses caractéristiques apparaissent rarement, parfois par pur hasard.
- Deux approches possibles :
 - Seuil par fréquence minimale (ce qui peut éliminer des informations utiles).
 - Intégrer une croyance a priori que tous les β doivent être nuls sauf en présence d'une forte évidence.


- On ajoute une pénalité quadratique aux valeurs élevées de β :

$$\mathcal{L}(\beta) = \sum_{i=1}^N \log P(y_i | x_i, \beta) - \eta \sum_{j=1}^F \beta_j^2$$

- Ceci équivaut à supposer que chaque β_j provient d'une distribution normale centrée sur 0.
- Le paramètre η contrôle la force de la pénalité (optimisé sur les données d'entraînement).

Exemple de régularisation L2

- Sans régularisation, certains coefficients peuvent être très élevés.
- Avec une régularisation modérée, les coefficients diminuent.
- Une forte régularisation pousse les coefficients vers zéro.



- Pour une classification à K classes, le modèle s'exprime comme suit :

$$P(Y = y \mid X = x; \beta) = \frac{\exp(x \cdot \beta_y)}{\sum_{y' \in Y} \exp(x \cdot \beta_{y'})}$$

- Ici, $Y = \{1, \dots, K\}$ et chaque classe dispose de son propre vecteur de coefficients β_y .

Exemple de coefficients en multiclasse

Caractéristique	Positive	Négative	Neutre
the	1.33	-0.80	-0.54
and	1.21	-1.73	-1.57
bravest	0.96	-0.05	0.24
love	1.49	0.53	1.01
loved	-0.52	-0.02	2.21
genius	0.98	0.77	1.53
not	-0.96	2.14	-0.71
fruit	0.59	-0.76	0.93
BIAS	-1.92	-0.70	0.94


- Note : Ici, trois ensembles de coefficients sont utilisés, un pour chaque classe (positive, négative, neutre).

- Support Vector Machines (SVM) :
 - Algorithme d'apprentissage supervisé utilisé pour la classification et la régression.
 - Particulièrement efficace pour séparer des classes dans un espace multidimensionnel.
- Principe :
 - Construire un hyperplan optimal qui sépare les différentes classes.
 - Maximiser la marge entre les classes.

Application aux romans policiers

- Objectif : Classer automatiquement des romans en « policier » vs « non-policier ».
- Caractéristiques possibles :
 - Fréquence de mots comme « enquête », « mystère », « crime », « détective »
 - Présence de noms propres typiques (Holmes, Poirot, Maigret, Rouletabille, Lecoq)
 - Structure narrative (énigme, révélation)
 - Vocabulaire judiciaire et criminel

Classes séparables vs non-séparables



- Hyperplan :
 - Plan de décision qui sépare les objets de classes différentes.
 - En 2D : une ligne ; en 3D : un plan ; en dimension supérieure : un hyperplan.
- Vecteurs de support :
 - Points de données les plus proches de l'hyperplan.
 - Ces points définissent la position et l'orientation de l'hyperplan.
- Marge :
 - Distance entre l'hyperplan et les vecteurs de support les plus proches.
 - L'objectif du SVM : maximiser cette marge.

Recherche de l'hyperplan optimal




Fig. 5 : Plusieurs hyperplans possibles (noir, bleu, orange). Le noir offre la meilleure séparation.

Hyperplan à Marge Maximale




Fig. 6 : L'hyperplan optimal maximise la marge entre les vecteurs de support des deux classes.

Algorithme

1. Générer plusieurs hyperplans candidats qui séparent les classes.
 2. Pour chaque hyperplan, calculer la marge (distance aux points les plus proches).
 3. Sélectionner l'hyperplan qui maximise la marge.
 4. Les points les plus proches de cet hyperplan deviennent les vecteurs de support.
- Une grande marge = meilleure généralisation.
 - Une petite marge = risque de surajustement.

- Certains problèmes ne peuvent pas être résolus avec un hyperplan linéaire.
- Solution : Utiliser une astuce du noyau (kernel trick).
- Le noyau transforme l'espace d'entrée en un espace de dimension supérieure où les données deviennent linéairement séparables.
- Exemple :
 - Espace 2D $(x, y) \rightarrow$ Espace 3D (x, y, z) avec $z = x^2 + y^2$.

- Noyau linéaire :
 - $K(x, x_i) = x \cdot x_i$
 - Pour des données linéairement séparables.
- Noyau polynomial :
 - $K(x, x_i) = (1 + x \cdot x_i)^d$
 - Où d est le degré du polynôme (à spécifier manuellement).
 - Utile pour des frontières courbes.
- Noyau RBF (Radial Basis Function) :
 - $K(x, x_i) = \exp(-\gamma \|x - x_i\|^2)$
 - Noyau le plus populaire pour la classification.
 - γ contrôle l'influence de chaque exemple.

- C (Paramètre de régularisation) :
 - Contrôle le compromis entre maximiser la marge et minimiser les erreurs de classification.
 - C petit : marge large, accepte plus d'erreurs (évite le surajustement).
 - C grand : marge étroite, minimise les erreurs (risque de surajustement).
- γ (pour le noyau RBF) :
 - γ faible : modèle simple, considère des points éloignés (sous-ajustement).
 - γ élevé : modèle complexe, considère uniquement les points proches (surajustement).

Exemple : Classification de romans policiers

```
from sklearn import svm
from sklearn.model_selection import train_test_split
from sklearn import metrics

# Diviser les données
X_train, X_test, y_train, y_test =
    train_test_split(features, labels,
                    test_size=0.3, random_state=109)

# Créer et entraîner le modèle SVM
clf = svm.SVC(kernel='linear')
clf.fit(X_train, y_train)

# Prédiction
y_pred = clf.predict(X_test)
```


Métriques de performance

Exactitude

```
print("Accuracy:",  
      metrics.accuracy_score(y_test, y_pred))
```

Précision

```
print("Precision:",  
      metrics.precision_score(y_test, y_pred))
```

Rappel

```
print("Recall:",  
      metrics.recall_score(y_test, y_pred))
```

Classification de romans (détectives vs non-détectives)

- Exactitude : 96.5%
 - Précision : 98.1%
 - Rappel : 96.3%
-
- Le modèle identifie correctement les romans policiers avec une grande fiabilité.
 - Les vecteurs de support correspondent aux romans « frontières » : par exemple, un roman psychologique avec enquête.

Critère	SVM	Rég. Logistique
Marge	Maximise la marge	Pas de notion de marge
Complexité	Plus complexe	Plus simple
Noyaux	Oui (kernel trick)	Non
Grands datasets	Lent	Rapide
Interprétabilité	Moyenne	Élevée

- Très efficace dans les espaces de grande dimension.
- Fonctionne bien même quand le nombre de dimensions dépasse le nombre d'échantillons.
- Utilise un sous-ensemble des données (vecteurs de support) : économie de mémoire.
- Polyvalent grâce aux différents noyaux disponibles.
- Robuste au surajustement, surtout en grande dimension.

- Temps d'entraînement élevé pour les grands ensembles de données.
- Choix du noyau et des hyperparamètres peut être délicat.
- Sensible au déséquilibre des classes.
- Moins performant quand les classes se chevauchent fortement.
- Résultats difficiles à interpréter (comparé à la régression logistique).

Quand utiliser les SVM ?

Cas d'usage recommandés

- Classification binaire ou multiclasse avec marge de séparation claire.
- Problèmes en haute dimension (texte, images).
- Données non linéairement séparables (avec noyaux appropriés).
- Ensembles de données de taille petite à moyenne.


Exemples d'applications

- Classification de textes (détection de spam, analyse de sentiment).
- Reconnaissance d'images et de caractères.
- Bioinformatique (classification de protéines).

- Les SVM cherchent l'hyperplan qui maximise la marge entre les classes.
- Les vecteurs de support sont les points déterminants pour la classification.
- L'astuce du noyau permet de traiter des problèmes non linéaires.
- Les hyperparamètres C et γ contrôlent le compromis biais-variance.
- Très efficaces pour la classification de textes (romans policiers, analyse de sentiment, etc.).

- Une partie critique dans le développement de nouveaux algorithmes et méthodes est l'évaluation, qui permet de démontrer leur efficacité.

```
scores = cross_val_score(estimator, X, y)
```



Données et partitionnement

- Espace d'instance : $\mathcal{X}$.
- Division typique des données :
 - Entraînement (80%) : apprentissage des modèles.
 - Développement (10%) : sélection du modèle.
 - Test (10%) : évaluation finale (à ne jamais consulter avant la fin).

Exemple de matrice de confusion

	Positive	Negative	Neutral
Positive	100	2	15
Negative	0	104	30
Neutral	30	40	70

Lignes : étiquettes réelles ; Colonnes : étiquettes prédites ($\hat{y}$).

Définition

$$\text{Accuracy} = \frac{1}{N} \sum_{i=1}^N I[\hat{y}_i = y_i],$$

où $I[x]$ vaut 1 si la condition est vraie, 0 sinon.

Définition (pour la classe Positive)

$$\text{Précision(POS)} = \frac{\sum_{i=1}^N I(y_i = \hat{y}_i = \text{POS})}{\sum_{i=1}^N I(\hat{y}_i = \text{POS})}.$$

La précision représente la proportion d'éléments prédits comme appartenant à une classe qui le sont réellement.

Définition (pour la classe Positive)

$$\text{Rappel(POS)} = \frac{\sum_{i=1}^N I(y_i = \hat{y}_i = \text{POS})}{\sum_{i=1}^N I(y_i = \text{POS})}.$$

Le rappel mesure la proportion des instances réelles d'une classe correctement prédites.

Définition

$$F = \frac{2 \times \text{précision} \times \text{rappel}}{\text{précision} + \text{rappel}}.$$

Le F-score est la moyenne harmonique entre la précision et le rappel.

- Choisir l'étiquette la plus fréquente dans les données d'entraînement (ne pas tenir compte des données de test).
- Prédire cette étiquette pour chaque point de données du test.