

TP d'introduction au TAL.

Aujourd'hui nous allons décortiquer des données linguistiques.

I. Devenir familier avec les données annotées.

1. Aller sur le site de Universal Dependencies :
<https://universaldependencies.org>

2. Choisir 2 langues, et pour chaque langue un corpus, le télécharger depuis GitHub : cliquez sur Master, une fois sur Github cliquez sur « <> code » puis sur « download zip ».

Prenez 1 que vous maîtrisez et 1 que vous ne maîtrisez pas du tout.

3. J'ai écrit une fonction qui sert à lire les fichiers CONLL-U de manière très sommaire. Plus d'infos sur le format :
<https://universaldependencies.org/format.html>

4. Pour chaque fichier train des 2 corpus, faire des statistiques sur les formes (token/type), les lemmes et les POS.

Ex: Loi de Zipf sur les formes puis lemmes; les mots les plus fréquents sont-ils équivalents dans les différentes langues choisies ? Nombres de formes par lemmes, &c.

Nous allons maintenant faire un peu de POS-tagging, une tâche classique de NLP. Comme c'est une tâche, c'est la combinaison d'un problème, d'une ou plusieurs mesures de réussite et d'un ou plusieurs jeux de données.

- Le problème : étant données une phrase dans une langue humaine, comment associer à chaque token (mot, ponctuation, smiley...) une partie du discours ?

- Une mesure de succès : étant donnée un ensemble de phrases annotées (les POS sont données pour chaque token) on peut calculer le pourcentage de prédictions correctes. (il existe d'autres mesures plus ou moins sensibles à différents aspects du problème)

- Un jeu de données : UD rend disponible des corpus annotés avec les POS pour plus de 100 de langues. (ici aussi, il y en a d'autres, d'ailleurs les POS ne sont pas universelles et différents corpus font différents choix d'annotation.)

I'. Avant d'aller plus loin, vous allez écrire une fonction pour tester la qualité d'un tagging. Cette fonction prend en argument deux listes de listes de POS. La première liste correspond à l'annotation prédéfinie, aussi gold ou vérité terrain, elle se compose d'une liste de POS pour chaque phrase. La deuxième liste correspond aux prédictions faites par un modèle.

Cette fonction calcule le pourcentage de formes correctement POS taggées. Pour le cas du dictionnaire fourni appliqué sur le dev de profiterole en ancien français, vous devriez obtenir 80.7864 % de bonnes prédictions.

Plus précisément, il y a 23728 formes en tout, 19169 reçoivent la bonne POS, 2307 reçoivent une mauvaise POS et 2252 n'en reçoivent pas du tout. En % cela donne : 80.7864 %, 9.7227 % et 9.4909 %.

II. Rule-based POS-tagging

Avant de voir tout un tas de méthodes vectorielles et neurales dans les semaines qui viennent, commençons avec des règles.

A chaque étapes, notez les scores que vous obtenez sur le jeu de dev. Commencez avec l'ancien français dans le fichier `tp_tagging_etudiant.py`, puis copiez le et modifiez le pour travailler sur une autre langue.

1. Ecrire 10 règles en n'utilisant qu'une partie de la forme. (souvent un suffixe) Notez bien l'importance de l'ordre des règles. Si un mot a déjà été étiqueté, doit-il être touché par les règles suivantes ?

2. Ecrire 10 règles pouvant utiliser une partie de la forme du mot et des voisins directs.

3. On ajoute maintenant la possibilité d'utiliser aussi les POS prédites dans le contexte comme features des règles.